







Tu universidad de postgrado

Your university for graduate studies

Tu universidad para una formación permanente

Your lifelong learning university

Tu universidad para una enseñanza innovadora

Your innovative education university

La universidad para tu futuro

The university for your future







UNIVERSIDAD

DE MÁLAGA










# Redes Neuronales Prácticas con PYTORCH (II)


**Redes Neuronales Convolucionales** 

### Recapitulemos (conceptos):








### Recapitulemos (red neuronal):



La introducción de una capa de neuronas permite combinar varias regiones (áreas) de decisión y así separar clases no linealmente separables











### **Recapitulemos (entrenamiento):**

#### **Crear modelo**

Clase con arquitectura Instanciación de clase

Hiperparámetros (optimizador, función de pérdida, estrategias, etc)

#### **Forward Pass**

En un batch, se calcula la salida de la red, y se almacenan operaciones.

#### **Backward Pass**

Calcula el gradiente de pérdida con respecto a entradas y actualiza pesos con optimizador para cada epoch (dataset)

#### Cálculo de pérdidas

Calculamos la distancia entre la salida esperada y la que genera la red

#### Evaluación


Evolución de las variables de pérdida, para orientar el entrenamiento





### La pregunta es:

¿Ya está? ¿Ya no hay más tipos de redes?










## Las redes convolucionales



### La convolución en imágenes







¡Nuestra visión funciona (aprox) así!



### La convolución en imágenes


<b>1</b> <sub>×1</sub>	1,0	1,	0	0
0,0	1,	1,0	1	0
0,,1	0,0	1,	1	1
0	0	1	1	0
0	1	1	0	0

**Image** 

Convolved Feature




UNIVERSIDA INTERNACIO DE ANDALUC





## UNIVERSIDAD INTERNACIONAL





### Parámetros de la convolución:

- Tamaño del **kernel** (*k*)
- Padding: relleno con valores (p)
- Stride: paso (s)

$0_2$	00	0,	0	0	0	0
0,	20	20	3	3	3	0
00	0,	1,	3	0	3	0
0	2	3	0	1	3	0
0	3	3	2	1	2	0
0	3	3	0	2	3	0
0	0	0	0	0	0	0

1	6	5	
7	10	9	
7	10	8	

Tamaño de salida: 
$$o = \lfloor rac{i+2p-k}{s} 
floor + 1$$



### ¿Cómo escribimos una convolución?

- Tamaño

- Padding


- Stride: p

- Dilatacio

### CONV2D

#### **CLASS**


torch.nn.
groups=1,
[SOURCE\_





### **Otras convoluciones:**


- La convolución se puede implementar matricialmente.
   La traspuesta de la matriz de convolución define la convolución transpuesta.
- Convolución agrupada.





### **Arquitecturas convolucionales**

- **ALEXNET** (y LeNet)








### **Arquitecturas convolucionales**

- Pooling





### **Arquitecturas convolucionales**

- Pooling

#### MAXPOOL2D


#### **CLASS**

```
torch.nn.MaxPool2d(kernel_size, stride=None, padding=0, dilation=1,
return_indices=False, ceil_mode=False)
[SOURCE]
```



### **Arquitecturas convolucionales**

- VGG16





¡A currar!



### Trucos de pytorch

Sequential models! ->
 Crear modelos de forma secuencial (como en keras) y rápida:

```
model = nn.Sequential(
          nn.Conv2d(1,20,5),
          nn.ReLU(),
          nn.Conv2d(20,64,5),
          nn.ReLU()
# Using Sequential with OrderedDict. This is functionally
# the same as the above code
model = nn.Sequential(OrderedDict([
          ('conv1', nn.Conv2d(1,20,5)),
          ('relu1', nn.ReLU()),
          ('conv2', nn.Conv2d(20,64,5)),
          ('relu2', nn.ReLU())
```




### **Transfer Learning**



## **Transfer learning**

- Transferir el aprendizaje en un dominio (ej. Imagenet) a otro nuevo dominio con un tamaño muestral menor.









### **Transfer learning**

- ¿Cómo?
  - a. Carga red pre-entrenada
  - b. Modifica capas a conveniencia (no convolucionales)
  - c. Re-entrena con LR baja

```
torchvision.models.vgg16(pretrained: bool = False, progress: bool = True, **kwargs: Any) → torchvision.models.vgg.VGG
[SOURCE]
```

VGG 16-layer model (configuration "D") "Very Deep Convolutional Networks For Large-Scale Image Recognition".

+ modelos: https://pytorch.org/vision/stable/models.html



### Regularización



### Mejora de la capacidad de generalización. Regularización

La regularización consiste en aplicar una penalización a la función de coste durante el proceso de optimización para evitar el sobreajuste a los datos de entrenamiento

Si definimos la función de coste como  $loss = error(y, \hat{y})$ Podemos añadir un término que incremente el loss:


$$loss = error(y, \hat{y}) + \lambda \Psi$$

$$\psi \rightarrow término de regularización$$



## Mejora de la capacidad de generalización. Regularización Tipos de regularización más comunes

### Dropout



b) After applying dropout.

- Se desactivan aleatoriamente un porcentaje predeterminado de neuronas durante el entrenamiento
- Evita que las neuronas memoricen parte de la entrada





### Mejora de la capacidad de generalización. Regularización Tipos de regularización más comunes

### Early Stopping

- Conseguir errores muy bajos durante el entrenamiento normalmente requiere de 1) un número alto de parámetros 2) realizar un número alto de iteraciones
- Ambas cosas hacen que la red sobreajuste los datos de entrenamiento

Early Stopping consiste en parar el proceso de entrenamiento cuando se haya alcanzado un determinado error, si dejar que se realicen más iteraciones que pueden llevar al sobreajuste.

